École Nationale d'Ingénieurs de Tunis
ENIT

Gestion des risques de crédit bancaire avec la méthode de scoring

Spécialité : **Actuariat, Sciences des Données et Contrôle Stochastique**

Réalisé par :

Zouaoui Ahmed Anas
Abbouz Hamza

Enseignant :

M. M'hamed GAIGI

Année Universitaire : **2025-2026**

Table des Matières

Introduction générale **4**

1 Aspect théorique du problème **5**
1.1 Problématique du risque de crédit et objectif de modélisation 5
1.1.1 Problématique 5
1.1.2 Objectif 5
1.2 Credit scoring 5
1.3 Significativité des paramétres estimés 7
1.3.1 Significativité Individuelle 7
1.3.2 Significativité globale 7

2 Modèle Logit **9**
2.1 Aspect théorique du modèle 9
2.2 Estimation des paramètres du modèle 10
2.3 Présentation des données 12
2.4 Statistiques descriptives 12
2.4.1 Matrice de corrélation 13
2.4.2 Répartition des classes de la variable 'Default' 14
2.4.3 Matrice de confusion 14
2.5 Winsorisation des données 15
2.6 Modélisation 16
2.6.1 Logit sur les données non winsorisées 16
2.6.2 Logit sur les données winsorisées 18

3 Modèle de Probit **20**
3.1 Modèle Probit et Estimation des Paramètres 20
3.2 Modélisation 21
3.2.1 Probit sur les données non winsorisées 21
3.2.2 Probit sur les données winsorisées 23

Conclusion et perspectives **25**

Table des figures

2.1 fonction sigmoïde 9
2.2 Exemple de nos données 12
2.3 description de nos donnée 12
2.4 Boîtes à moustaches 13
2.5 Matrice de corrélation 13
2.6 répartition des classes pour la variable 'Default' 14
2.7 Matrice de confusion 15
2.8 Données winsorisées 15
2.9 Statistiques descriptives après winsorisation 16
2.10 Statistiques descriptives après winsorisation 16
2.11 Résultats du modèle logit appliqué aux 5 ratios non winsorisées 17
2.12 Résultats du modèle logit appliqué aux 3 ratios non winsorisées 17
2.13 Comparaison du modèle à 5 paramètres et celui à 3 17
2.14 Résultats du modèle logit appliqué aux 5 ratios winsorisées 18
2.15 Résultats du modèle logit appliqué aux 3 ratios winsorisées 18
2.16 comparaison de modèle à 5 paramètres et celui à 3 18

3.1 Probit 20
3.2 Résultats du modèle Probit appliqué aux 5 ratios non winsorisées 22
3.3 Résultats du modèle Probit appliqué aux 3 ratios non winsorisées 22
3.4 comparaison de modèle à 5 paramètres et celui à 3 22
3.5 Résultats du modèle Probit appliqué aux 5 ratios winsorisées 23
3.6 Résultats du modèle Probit appliqué aux 4 ratios winsorisées 23
3.7 comparaison de modèle à 5 paramètres et celui à 4 23

Introduction générale

La gestion des risques de crédit bancaire constitue aujourd'hui un pilier essentiel de la stabilité du système financier. Avec la croissance continue du volume du crédit, la diversification des produits financiers et la volatilité des environnements économiques, les institutions bancaires doivent être capables d'identifier, de mesurer et d'anticiper les risques de défaut associés à leurs portefeuilles. Un défaut non anticipé peut entraîner des pertes significatives, détériorer la solvabilité de la banque et entraver sa capacité à soutenir l'économie réelle.

Dans cette perspective, les cadres réglementaires internationaux tels que **Bâle II**, **Bâle III** et plus récemment **Bâle IV** ont imposé des exigences plus strictes en matière de gestion du risque de crédit, de calcul des fonds propres et de contrôle interne. Ces accords prudentiels insistent particulièrement sur l'importance d'outils analytiques robustes et de modèles fiables pour estimer la probabilité de défaut et maîtriser les pertes attendues.

Les méthodes de **scoring de crédit** occupent une place centrale dans ce dispositif. Elles permettent d'évaluer la qualité d'un emprunteur à partir de ses caractéristiques financières, socio-économiques ou comportementales, en attribuant un score reflétant sa probabilité de défaut. Ces techniques améliorent l'objectivité des décisions d'octroi, renforcent la cohérence du processus d'évaluation et contribuent à une meilleure allocation du capital au sein des institutions financières.

Au cœur de ces approches, les modèles économétriques de régression binaire, notamment les modèles **logit** et **probit**, constituent des outils de prédiction particulièrement adaptés pour estimer la probabilité de défaut. Leur capacité à modéliser une variable qualitative — défaut ou non-défaut — à partir d'un ensemble de facteurs explicatifs, tout en restant interprétables et conformes aux attentes réglementaires, explique leur large adoption dans les travaux académiques et pratiques.

Le présent projet s'inscrit dans cette logique et propose d'appliquer et de comparer ces deux modèles dans un cadre de scoring de crédit. Il est structuré comme suit :

- **Chapitre 1 :** présentation théorique du risque de crédit, des enjeux de sa gestion et des fondements du scoring.
- **Chapitre 2 :** développement, estimation et analyse du **modèle logit** .
- **Chapitre 3 :**développement, estimation et analyse du **modèle probit**.

Enfin, une **conclusion générale** viendra résumer les principaux résultats, souligner les limites de l'étude et proposer des pistes d'amélioration pour des modèles de scoring mieux adaptés aux exigences actuelles du secteur bancaire.

Chapitre 1

Aspect théorique du problème

Ce chapitre présente la problématique du projet, qui consiste à développer un modèle capable d'évaluer le risque de défaut des emprunteurs. Il expose les objectifs retenus, notamment la construction d'un outil de prédiction fiable et interprétable. Une définition synthétique du credit scoring est ensuite introduite afin de situer le cadre conceptuel de la modélisation. Enfin, le chapitre aborde la significativité des paramètres estimés, indispensable pour identifier les variables influençant réellement la probabilité de défaut. Ce chapitre pose ainsi les bases théoriques et méthodologiques indispensables qui serviront de fondement à l'application pratique, à la modélisation et à l'interprétation des résultats qui seront développées dans le Chapitre 2.

1.1 Problématique du risque de crédit et objectif de modélisation

1.1.1 Problématique

— La banque prête de l'argent aux entreprises et aux particuliers, la banque est donc le créancier.

— Ces derniers sont obligés de rembourser le crédit suivant un échéancier (ensemble d'échéances).

— Un événement peut se produire : les emprunteurs peuvent faire défaut, c'est-à-dire être incapables de payer leur dette.

1.1.2 Objectif

Modéliser la probabilité de défaut des emprunteurs à travers la méthode de scoring, afin de disposer d'un outil d'aide à la décision pour l'octroi de crédits.

1.2 Credit scoring

La méthode de scoring ou credit scoring est un outil inventé aux États-Unis dans les années 1950, qui sert à évaluer le risque financier que peut représenter un emprunteur pour un établissement prêteur.
Le scoring bancaire a cependant une influence directe sur l'octroi du crédit, dans le sens où il peut améliorer ou nuire à la qualité d'un profil emprunteur. Un mauvais score réduit

les chances d'obtenir un emprunt, tandis qu'un bon score peut aider à obtenir un meilleur taux.
Le principe de cette méthode alors est de déterminer un score ou un niveau qui devrait représenter le risque spécifique d'un prêteur. Ce score est obtenu en considérant différents paramètres et il est important de choisir quel paramètre sur le pouvoir prédictif du système.
Un score résume l'information disponible sur l'mprunteur dans des facteurs qui affectent la probabilité de défaut :

$$\text{score}_i = b_0 + b_1 x_{i1} + b_2 x_{i2} + ... + b_k x_{ik}$$

Où i : le numéro du client.
$(x_{i1}, x_{i2}, ..., x_{ik})$: facteurs explicatifs
$(b_0, b_1, ..., b_k)$: paramètre à estimer dépend de i.
Dans ce projet, on s'intéresse à 5 ratios financiers qui sont les suivants :

$$R_1 = \frac{\text{Fonds de roulement}}{\text{Actif total}} = \frac{WC}{TA}$$

Ce ratio mesure la part des actifs financés par le fonds de roulement. Il permet d'évaluer la solidité financière à court terme et la capacité de l'entreprise à couvrir ses dettes courantes.

$$R_2 = \frac{\text{Bénéfices non distribués}}{\text{Actif total}} = \frac{RE}{TA}$$

Ce ratio mesure la proportion des bénéfices accumulés (non distribués) dans le financement total de l'entreprise, c'est-à-dire la part des ressources internes (autofinancement) par rapport à l'ensemble de l'actif.

$$R_3 = \frac{\text{Bénéfices avant impôts et charges}}{\text{Actif total}} = \frac{EBIT}{TA}$$

Ce ratio mesure la rentabilité économique de l'entreprise indépendamment de sa structure financière et de sa fiscalité. Plus il est élevé, plus l'entreprise génère efficacement du profit à partir de ses actifs.

$$R_4 = \frac{\text{Capitalisation boursière}}{\text{Passif total}} = \frac{ME}{TL}$$

Ce ratio met en relation la valeur de marché de l'entreprise avec son endettement total. Il donne une idée de la confiance des investisseurs par rapport à la solidité financière de l'entreprise.

$$R_5 = \frac{\text{Ventes}}{\text{Actif total}} = \frac{S}{TA}$$

Ce ratio, appelé aussi rotation des actifs, mesure l'efficacité avec laquelle l'entreprise utilise ses actifs pour générer des ventes. Un ratio élevé traduit une bonne utilisation des ressources disponibles.

1.3 Significativité des paramétres estimés

1.3.1 Significativité Individuelle

Test de Wald

Le Test de Wald est un test paramétrique économétrique fondamental. Son objectif est de déterminer si les variables explicatives d'un modèle sont statistiquement significatives. Il s'agit de tester l'hypothèse de nullité de chaque paramètre b_j du modèle, basée sur les hypothèses suivantes :

- **Hypothèse Nulle (H_0) :** $b_j = 0$ (La variable n'est pas significative).
- **Hypothèse Alternative (H_1) :** $b_j \neq 0$ (La variable est significative).

La statistique du test notée (t_j) est définie comme suit :

$$t_j = \frac{b_j - 0}{SE(b_j)} \sim t_{(N-k)} \quad \text{(Student)} \tag{1.1}$$

où b_j est l'estimation du paramètre.

L'erreur standard de l'estimation ($SE(b_j)$) est donnée par :

$$SE(b_j) = \sqrt{-\text{Hess}^{-1}_{jj}(\ln \mathcal{L}(\mathbf{b}))} \tag{1.2}$$

Le terme t_j mesure la distance entre notre estimation b_j et la valeur hypothétique $b_j = 0$, exprimée en nombre d'erreurs standard. Plus $|t_j|$ est grande, plus nous sommes confiants que b_j est significativement différent de zéro.

Règle de Décision et p-value

Approximation : Remarquons que si le nombre de degrés de liberté $N - k > 30$, la loi de Student peut être approximée par la loi Normale centrée réduite $\mathcal{N}(0, 1)$.

Dans ce cas, la valeur de p_value est calculée par :

$$p_value = 2\left(1 - F_{\mathcal{N}(0,1)}(|t_j|)\right) \tag{1.3}$$

où $F_{\mathcal{N}(0,1)}$ est la fonction de répartition de la loi normale standard.
Si la p-value est inférieure au seuil critique (généralement $\alpha = 5\%$), on rejette l'hypothèse H_0 et on conclut que le paramètre b_j est statistiquement significative.

1.3.2 Significativité globale

Notre modèle est un modèle de régression non linéaire, nous utilisons donc les tests statistiques suivants :

Pseudo-R^2

Ce test a été proposé par **Daniel MacFader** comme une généralisation du test R^2. La métrique associée est :

$$\text{Pseudo-}R^2 = 1 - \frac{\ln(L)}{\ln(L_0)} \tag{1.4}$$

Où :

— L : Vraisemblance du modèle à $K+1$ paramètres (le modèle estimé).

— $\mathcal{L}_0$: Vraisemblance du modèle à un paramètre..

Plus le Pseudo-R^2 est proche de 1, plus le modèle à $K+1$ paramètres gagne en significativité par rapport au modèle restreint.

Test de Rapport de Vraisemblance (Likelihood Ratio Test)

Il permet de tester l'hypothèse de nullité des coefficients de toutes les variables explicatives simultanément. C'est-à-dire que nous testons les hypothèses suivantes :

– $\boldsymbol{H_0}$: $b_0 = b_1 = \cdots = b_k = 0$ (Aucune des variables explicatives n'est significative).

– $\boldsymbol{H_1}$: Les- paramètres ne sont pas tous nuls.

La **Statistique du test** (LR) se définit comme suit :

$$LR = 2\left(\ln(L) - \ln(L_0)\right) \tag{1.5}$$

Une plus grande valeur de LR indique une meilleure significativité globale du modèle. Asymptotiquement, la statistique LR suit une distribution du Chi-deux (χ^2) :

$$LR \sim \chi^2_{(k)} \tag{1.6}$$

où k est le nombre de variables explicatives (le nombre de restrictions testées).

Conclusion :

Ce chapitre a permis de clarifier la problématique du projet et de définir les objectifs liés à la construction d'un modèle de prédiction du risque de défaut. Nous avons présenté le concept de credit scoring ainsi que son rôle central dans l'évaluation de la qualité des emprunteurs. L'importance de la significativité des paramètres estimés a également été soulignée, car elle conditionne la robustesse et l'interprétabilité de tout modèle statistique. L'ensemble de ces éléments fournit le cadre méthodologique nécessaire pour aborder les modèles économétriques adaptés aux variables binaires. Dans ce sens, le chapitre suivant est consacré au modèle logit, qui constitue la première approche retenue pour estimer la probabilité de défaut.

Chapitre 2

Modèle Logit

2.1 Aspect théorique du modèle

Après avoir défini les indicateurs financiers utilisés dans le calcul du score de crédit, il est nécessaire d'adopter un modèle statistique permettant de relier ces variables explicatives à la probabilité de défaut d'un emprunteur. Parmi les modèles les plus utilisés dans la littérature économique et financière figure le modèle Logit, en raison de sa simplicité, de son interprétation probabiliste et de ses bonnes propriétés statistiques.
Dans notre étude, nous avons utilisé le modèle logit afin d'estimer les coefficients $(b_0, b_1, ..., b_k) = b$. Pour ce faire, On va relier la probabilité de défaut au score :

$$\text{proba(défaut)} = F(\text{score}_i) \in [0, 1]$$

où F est la fonction de répartition de la distribution logistique appelée aussi fonction **sigmoïde** et explicitement définie par :

$$F(x) = \frac{1}{1 + exp(-x)} = \frac{exp(x)}{1 + exp(x)}$$

alors

$$f(x) = \frac{exp(-x)}{(1 + exp(-x))^2} = F'(x)$$

avec

$$E(x) = 0; \quad \text{Var}(x) = \frac{\pi^2}{3}; \quad x \sim \text{Logistique}$$

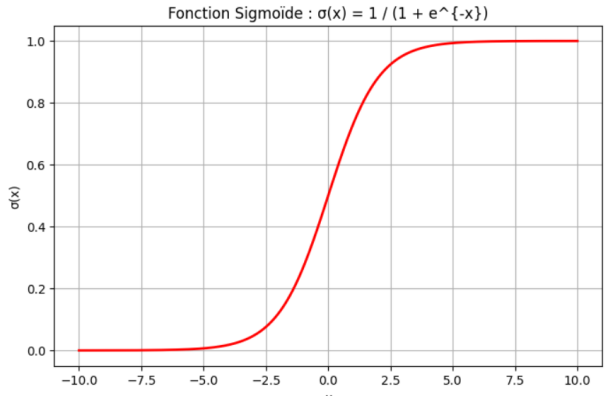


FIGURE 2.1 – fonction sigmoïde

Ainsi, la fonction sigmoïde transforme la combinaison linéaire des variables explicatives en une probabilité comprise entre 0 et 1. Elle relie ainsi le score de l'emprunteur à sa probabilité de défaut. Sa forme en S montre que les variations du score influencent davantage la probabilité de défaut dans les zones intermédiaires, la figure ci-dessus illustre cette relation.

2.2 Estimation des paramètres du modèle

Comme donnée, on a : $x_i = (x_{i1}, x_{i2}, \ldots, x_{i5})$ et on veut estimer $b = (b_0, b_1, \ldots, b_5)$. Pour ce faire, on utilise le principe du maximum de vraisemblance avec

$$\text{proba}(\text{défaut}_i) = F(\text{score}_i) = F\Big(b_0 + b_1 x_{i1} + \cdots + b_k x_{ik}\Big)$$

$$= F(b^T x_i), \quad \text{où } x_i = (1, x_{i1}, x_{i2}, \ldots, x_{ik})$$

$$\text{proba}(\text{non-défaut}_i) = 1 - F(b^T x_i)$$

$$L_i(b) = F\big(b^\top x_i\big)^{y_i}\big(1 - F(b^\top x_i)\big)^{1-y_i} \quad \text{où} \quad y_i = \begin{cases} 1 & \text{s'il y a défaut} \\ 0 & \text{sinon} \end{cases}$$

L_i : Loi de Bernoulli de paramètre $p = F(b^\top x_i), \quad (i \in \{1, \ldots, N\})$

Rappel

Soit X_i une suite de variables aléatoires i.i.d. suivant la loi de Bernoulli de paramètre p. Alors :

$$P(X = x) = p^x (1-p)^{1-x}, \quad \text{pour } x \in \{0, 1\}.$$

$$L(x_1, \ldots, x_n, p) = \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i}$$

La vraisemblance de l'échantillon alors est définit comme suit :

$$L(b) = \prod_{i=1}^{N} L_i(b) = \prod_{i=1}^{N} \left[F(b^T x^i)^{y_i}\left(1 - F(b^T x^i)\right)^{1-y_i}\right]$$

Pour estimer les paramètres du modèle, nous cherchons à maximiser la vraisemblance, ce qui revient à maximiser la log-vraisemblance. Ainsi, le problème d'estimation peut s'écrire sous la forme suivante :

$$\max_b \{\ln(L(b))\}$$

en appliquant le logarithme, on obtient :

$$ln(L(b)) = \sum_{i=1}^{N} (y_i ln(F(b^T x_i)) + (1 - y_i) ln(1 - F(b^T x_i)))$$

maintenant, en appliquant le derivé par rapport à b

$$\frac{\partial \ln(L(b))}{\partial b_j} = \sum_{i=1}^{N} \left[y_i \frac{F'(b^T x_i)}{F(b^T x_i)} x_{ij} - (1 - y_i) \frac{F'(b^T x_i)}{1 - F(b^T x_i)} x_{ij} \right]$$

Nous donnons ainsi les propriétés de la fonction sigmoïde suivantes :

$$\begin{cases} \dfrac{F'}{F} = 1 - F \\ \dfrac{F'}{1-F} = F \end{cases}$$

Nous pouvons conclure alors que :

$$\frac{\partial \ln(L(b))}{\partial b_j} = \sum_{i=1}^{N} \left[y_i(1 - F(b^T x_i))x_{ij} - (1 - y_i)(F(b^T x_i)x_{ij}) \right]$$

donc

$$\nabla_b \ln(L(b)) = \sum_{i=1}^{N} (y_i - F(b^T x^i))x_j^i$$

Le problème se ramène donc à la résolution de l'équation suivante :

$$\nabla_b \ln(L(b)) = 0_{\mathbb{R}^{k+1}}$$

L'une des méthodes pour résoudre ce problème est l'algorithme de **Newton**.

Algorithme de Newton

est une méthode itérative utilisée pour résoudre des équations non linéaires, c'est-à-dire trouver la solution x telle que f(x) = 0.
on donne l'algorithme suivant :

$$\begin{cases} x^0 \quad \text{donnée} \\ x^{n+1} = x^n - \dfrac{f(x^n)}{f'(x^n)} \end{cases}$$

On considère ici $f(b) = \nabla_b \ln(L(b))$.
La solution b^* vérifie $f(b^*) = 0$, et son unicité découle de la coercivité de $\ln(L(b))$.
L'algorithme de Newton nécessite ensuite le calcul de la Hessienne de $\ln(L(b))$, notée $H(b)$.

$$\frac{\partial^2 \ln(L(b))}{\partial b_j \partial b_k} = -\sum_{i=1}^{N} F'(b^T x_i)x_{ij}x_{ik}$$

Or $F' = (1 - F)F$
Donc $H(b)$ s'écrit sous la forme suivante :

$$H(b) = -\sum_{i=1}^{N} F(b^T x_i)(1 - F(b^T x_i))x_{ij}x_{ik}$$

Notre algorithme peut s'écrire alors sous la forme suivante :

$$\begin{cases} b^{(0)} \quad \text{donnée} \\ b^{(n+1)} = b^{(n)} - \left(H(b^{(n)})\right)^{-1} \nabla_b \ln(L(b^{(n)})) \end{cases}$$

2.3 Présentation des données

La base de données utilisée regroupe des informations financières d'entreprises observées sur plusieurs années. Chaque entreprise est identifiée par un numéro unique "ID" et chaque ligne correspond à une entreprise à une année donnée, soit un total de 4001 observations. La variable "Default" indique si l'entreprise a connu un défaut (1) ou non (0), tandis que les autres variables représentent des indicateurs financiers destinés à l'analyse du risque de faillite.

ID	Year	Default	WC/TA	RE/TA	EBIT/TA	ME/TL	S/TA
1	1999	0	0,501	0,307	0,043	0,956	0,335
1	2000	0	0,55	0,32	0,05	1,06	0,33
1	2001	0	0,45	0,23	0,03	0,80	0,25
1	2002	0	0,31	0,19	0,03	0,39	0,25
1	2003	0	0,45	0,22	0,03	0,79	0,28
1	2004	0	0,46	0,22	0,03	1,29	0,32
2	1999	0	0,01	-0,03	0,01	0,11	0,25

FIGURE 2.2 – Exemple de nos données

2.4 Statistiques descriptives

	WC/TA	RE/TA	EBIT/TA	ME/TL	S/TA
MOYENNE	0,143	0,210	0,052	1,954	0,304
MEDIANE	0,117	0,219	0,052	1,136	0,261
STDEV	0,17076261	0,33254945	0,02959551	2,994475	0,20579405
SKEWNESS	-1,01453171	-2,55489151	-4,84436164	7,75072812	4,48100441
KURT	17,6822686	17,441196	85,9974266	103,127537	71,2152414
QUANTILE / EXTREME VALUES					
MIN	-2,240	-3,312	-0,592	0,024	0,036
0,50%	-0,32840025	-1,71747835	-0,04683852	0,05346396	0,06221757
1%	-0,16965424	-0,92362929	-0,01620374	0,0784782	0,07030681
5%	-0,06214272	-0,25130578	0,01763609	0,22014251	0,09858148
95%	0,44170881	0,65052497	0,0921256	5,5982808	0,68057118
99%	0,57699894	0,8968113	0,12062265	14,4558224	1,05380148
99,50%	0,62629039	0,93901758	0,1348711	18,9408983	1,12719393
MAX	0,766	1,640	0,198	60,607	5,008

FIGURE 2.3 – description de nos donnée

Les statistiques descriptives montrent que les entreprises présentent en moyenne une situation financière positive, mais avec une forte hétérogénéité. De plus, certains ratios négatifs traduisent des difficultés pour certaines firmes. Les écarts-types élevés, ainsi que les valeurs importantes de skewness et kurtosis, révèlent des distributions très dispersées et asymétriques, avec des valeurs extrêmes. Globalement, la base contient à la fois des entreprises saines et d'autres en situation plus fragile, ce qui est typique des données utilisées pour l'analyse du risque de défaut.
Afin de mieux identifier graphiquement la présence de valeurs extrêmes, nous procédons à la visualisation des ratios sous forme de boîtes à moustaches (boxplots). Cette représentation permet de repérer rapidement les points situés en dehors des limites statistiques normales, révélateurs de valeurs aberrantes susceptibles d'influencer négativement les estimations et les modèles de scoring.

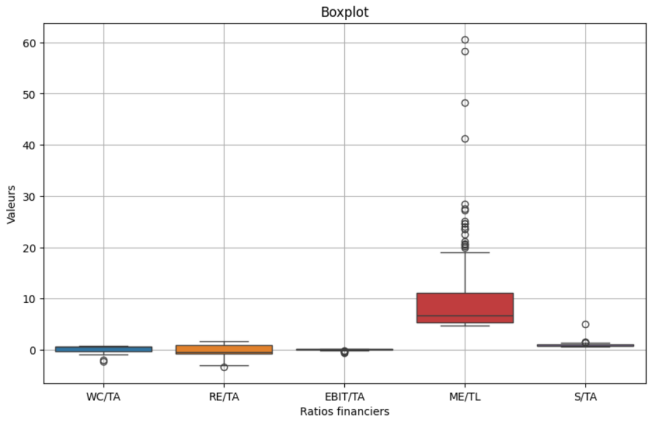


FIGURE 2.4 – Boîtes à moustaches

L'analyse visuelle des boxplots constitue ainsi une étape essentielle avant l'application de techniques de traitement comme la winsorisation, qui visent à réduire l'impact de ces valeurs extrêmes tout en conservant l'information pertinente.

2.4.1 Matrice de corrélation

Après avoir identifié et analysé les éventuelles valeurs aberrantes à l'aide des boxplots, il est important d'examiner la structure interne du jeu de données. En particulier, il convient d'évaluer la manière dont les variables explicatives interagissent entre elles. Pour cela, nous étudions la matrice de corrélation, qui permet de mesurer l'intensité et le sens des relations linéaires entre les différentes ratios. Cette étape est essentielle avant toute modélisation , car elle permet de détecter la présence éventuelle de dépendances fortes susceptibles d'introduire de la redondance ou de la multicolinéarité dans les modèles.

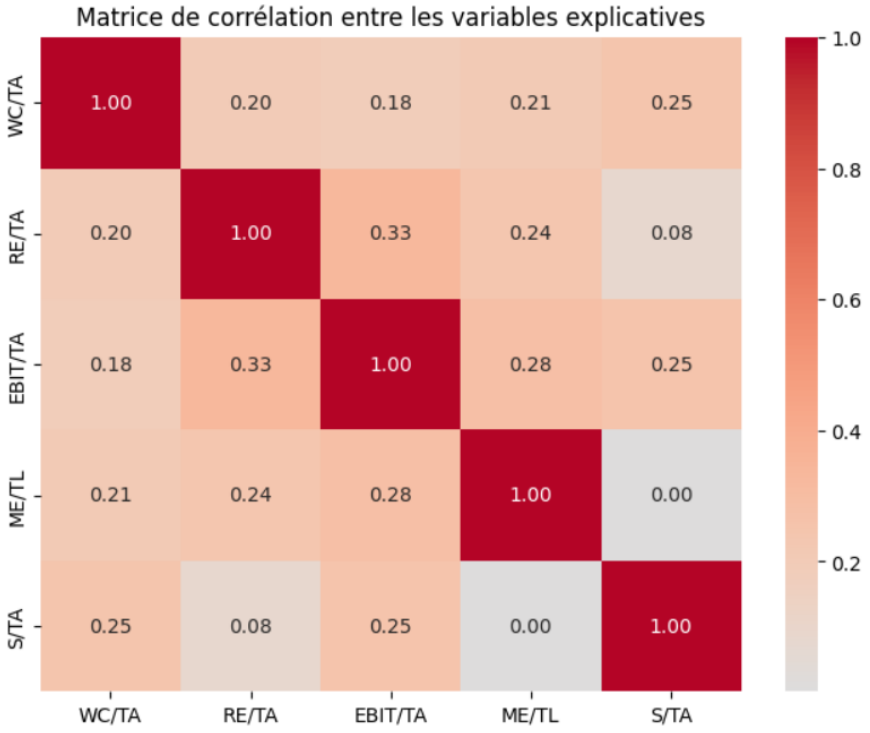


FIGURE 2.5 – Matrice de corrélation

La matrice de corrélation montre que les ratios sont faiblement corrélés entre eux, ce qui confirme leur indépendance statistique.
Chaque ratio apporte une information propre et non redondante, améliorant ainsi la qualité explicative du modèle.
Cette indépendance facilite les calculs, stabilise les coefficients et optimise les performances de la modélisation.

2.4.2 Répartition des classes de la variable 'Default'

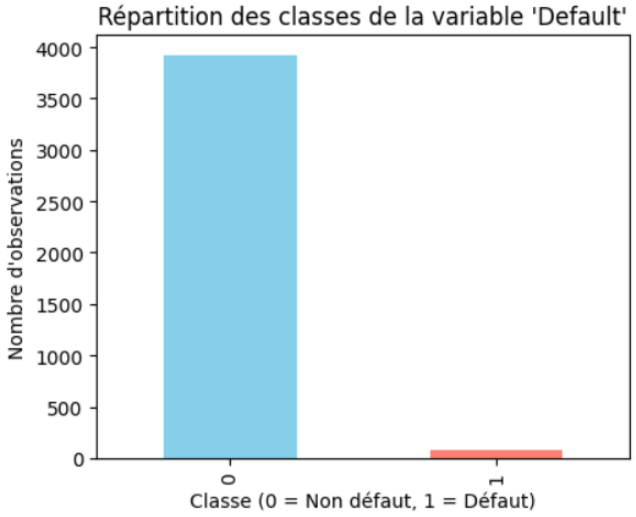


FIGURE 2.6 – répartition des classes pour la variable 'Default'

Le graphique montre une forte disproportion entre les deux classes de la variable Default, avec une majorité écrasante d'entreprises non défaillantes (classe 0) par rapport aux entreprises défaillantes (classe 1). Ce déséquilibre indique que la base de données est très asymétrique, ce qui peut biaiser l'apprentissage du modèle vers la classe majoritaire. Une telle répartition rend plus difficile la détection correcte des cas de défaut, souvent rares mais les plus importants à identifier.

2.4.3 Matrice de confusion

Après avoir examiné la matrice de corrélation afin d'évaluer les relations linéaires entre les variables explicatives et de vérifier l'absence de multicolinéarité, nous pouvons maintenant passer à l'évaluation de la performance du modèle de classification. Pour cela, nous utilisons la matrice de confusion, qui permet d'analyser de manière détaillée la capacité du modèle à distinguer correctement les observations des deux classes. Cette étape est essentielle pour mesurer la qualité prédictive du modèle et compléter l'analyse statistique précédemment réalisée.

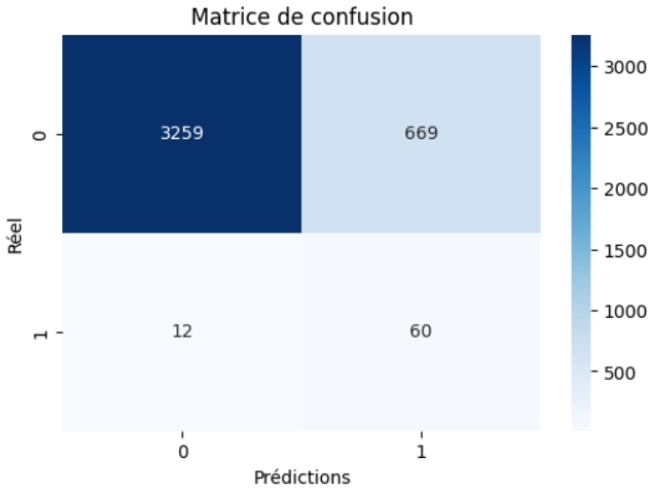


FIGURE 2.7 – Matrice de confusion

La matrice de confusion permet d'évaluer la capacité du modèle à distinguer correctement les entreprises en difficulté (classe 1) de celles en situation saine (classe 0). Parmi les 3928 observations réelles de la classe 0, le modèle en a correctement classé 3259, soit une forte proportion de vrais négatifs. En revanche, 669 observations ont été à tort prédites comme appartenant à la classe 1, ce qui correspond à des faux positifs. Concernant la classe 1, sur 72 cas réels, le modèle en identifie correctement 60 (vrais positifs), mais en classe encore 12 comme sains (faux négatifs). Dans l'ensemble, le modèle montre une bonne capacité à repérer les entreprises non défaillantes, mais présente davantage de difficultés à détecter avec précision les entreprises réellement défaillantes, ce qui se traduit par un taux non négligeable de faux positifs et quelques faux négatifs. Cela suggère que le modèle peut être amélioré, notamment en ajustant le seuil de décision ou en explorant des méthodes de rééquilibrage des données.

2.5 Winsorisation des données

La technique de winsorisation consiste à remplacer les valeurs extrêmes par des valeurs plus modérées. En effet, pour un niveau de winsorisation $\alpha \in [0, 1]$, on remplace les valeurs de la distribution au-dessous du centile α (resp. au-dessus du centile $1 - \alpha$) par celle du centile α (resp. par celle du centile $1 - \alpha$).

WC/TA	RE/TA	EBIT/TA	ME/TL	S/TA
0,5007986	0,3068458	0,0433734	0,9562708	0,3347738
0,5477802	0,3222137	0,0518426	1,064545	0,3345913
0,4510005	0,2251504	0,0268132	0,8040959	0,2455852
0,3068869	0,1919362	0,0300583	0,3870105	0,2534376
0,4472462	0,217368	0,032458	0,7916385	0,2755307
0,4576187	0,2240644	0,0318383	1,288137	0,3181927
0,0060338	-0,0284001	0,006764	0,1102698	0,2549882
-0,1147283	-0,1186598	0,0308919	0,1496446	0,3157223
0,0613052	-0,1094951	0,0399474	0,4101503	0,2860254
0,0506413	-0,0866989	0,0453552	0,2533544	0,3420563
0,1210532	-0,1140413	0,0372976	0,4571765	0,3121222

FIGURE 2.8 – Données winsorisées

Après l'application de cette méthode nous obtenons les statistiques descriptives suivantes :

	WC/TA	WC/TA	EBIT/TA	ME/TL	S/TA
MOYENNE	0,145	0,217	0,052	1,871	0,302
MEDIANE	0,117	0,219	0,052	1,136	0,261
STDEV	0,15370459	0,28375354	0,02300654	2,24181728	0,18766701
SKEWNESS	0,62950239	-0,9525027	0,1350102	3,29766685	1,68154545
KURT	0,01277201	3,2023598	1,0988754	13,4786476	3,42269499
QUANTILE / EXTREME VALUES					
MIN	-0,170	-0,924	-0,016	0,078	0,070
0,50%	-0,16965424	-0,92362929	-0,01620374	0,0784782	0,07030681
1%	-0,16962064	-0,92345447	-0,01620053	0,07852265	0,07030819
5%	-0,06212881	-0,25125144	0,0176408	0,22016851	0,09858544
95%	0,44185211	0,65050958	0,09212363	5,5979722	0,68052155
99%	0,57699513	0,8967985	0,12060483	14,4409424	1,05374939
99,50%	0,57699606	0,89680162	0,12060919	14,4445781	1,05376212
MAX	0,577	0,897	0,121	14,445	1,054

FIGURE 2.9 – Statistiques descriptives après winsorisation

Nous remarquons que les valeurs extrêmes ont été limitées, ce qui a rendu les variables plus stables et moins dispersées. Les coefficients d'asymétrie, désormais proches de zéro, indiquent que les données sont presque centrées autour d'une distribution normale, tandis que les coefficients d'aplatissement (kurtosis) proches de zéro montrent une forme de distribution plus régulière pour l'ensemble des variables.
De plus, nous remarquons que la technique de winsorisation a contribué à diminuer l'impact des valeurs extrêmes en les rapprochant du reste des observations.

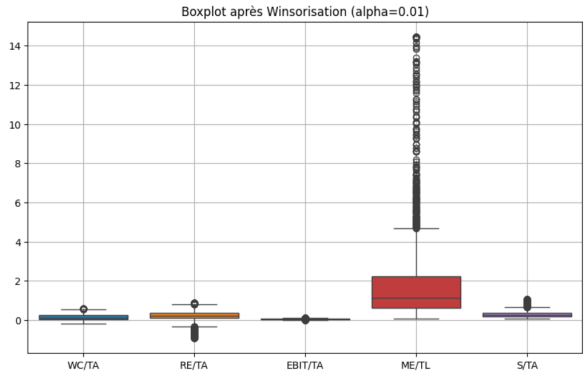


FIGURE 2.10 – Statistiques descriptives après winsorisation

2.6 Modélisation

2.6.1 Logit sur les données non winsorisées

Nous avons appliqué le modèle logit afin d'estimer les coefficients $b_0, b_1, \ldots, b_5$ associés aux notre cinq ratios financiers et l'estimation a été réalisée à l'aide de l'algorithme de Newton-Raphson, qui permet de maximiser la fonction de vraisemblance.

Variables non winsorisées						
	cst	WC/TA	RE/TA	EBIT/TA	ME/TL	S/TA
b	-2,543476391	0,4143941	-1,45402065	-7,9990595	-1,59359421	0,61972076
t	-9,560885211	0,72386052	-6,3359838	-2,9599789	-4,92754261	1,77469474
p-value	0	0,46915137	2,3583E-10	0,0030766	8,327E-07	0,0759483
pseudo-R^2	0,222057833	0,22205783	0,22205783	0,22205783	0,22205783	0,22205783
LR	160,1479719	160,147972	160,147972	160,147972	160,147972	160,147972
P-value	9,20493E-33	9,2049E-33	9,2049E-33	9,2049E-33	9,2049E-33	9,2049E-33
ln(L0)	-360,5996901	0	0	0	0	0
ln(L)	-280,5257042	0	0	0	0	0
nbre de itration	20	0	0	0	0	0

FIGURE 2.11 – Résultats du modèle logit appliqué aux 5 ratios non winsorisées

D'après les résultats, les ratios RE/TA, EBIT/TA et ME/TL présentent des p-values inférieures au seuil de 1 %, ce qui confirme leur significativité statistique. En revanche, les ratios WC/TA et S/TA affichent des p-values supérieures à 1 %, alors ces deux ratios peuvent être éliminés du modèle et on réestime le modèle logit uniquement sur les trois variables significatives..
Le pseudo R^2 obtenu (0,222) montre que le modèle possède une capacité explicative modérée, ce qui reste satisfaisant dans le cadre d'un modèle logit appliqué à des données financières.

b	-2,318334754	-1,4197444	-7,17936085	-1,6156155
t	-9,838656301	-6,2060676	-2,63426665	-4,9747564
p-value	0	5,4327E-10	0,00843192	6,533E-07
pseudo-R^2	0,217361499	0,2173615	0,2173615	0,2173615
LR	156,7609781	156,760978	156,760978	156,760978
P-value	9,16409E-34	9,1641E-34	9,1641E-34	9,1641E-34
ln(L0)	-360,5996901	0	0	0
ln(L)	-282,2192011	0	0	0
nbre de itration	20	0	0	0

FIGURE 2.12 – Résultats du modèle logit appliqué aux 3 ratios non winsorisées

Les résultats obtenus montrent que toutes les p-values sont inférieures au seuil de 1 %, ce qui confirme la significativité statistique des trois ratios retenus.
Le pseudo R^2 reste stable (0,217), indiquant que la réduction du nombre de variables n'a pas entraîné de perte notable d'information.
La dernière étape consiste à effectuer le test du rapport de vraisemblance (Likelihood Ratio Test) afin de comparer le modèle à 5 paramètres (modèle initial) et celui à 3 paramètres. Ce test permet de vérifier si la suppression des deux variables (WC/TA et S/TA) entraîne une dégradation significative de la qualité d'ajustement du modèle.

LR	3,386993734
p-val	0,183875411

FIGURE 2.13 – Comparaison du modèle à 5 paramètres et celui à 3

Le résultat donne une p-valeur de 0.18, supérieure aux seuils usuels de 1% et 5%.
Cette valeur indique que la suppression des deux variables n'entraîne pas de perte significative d'information statistique. Ainsi, avant le traitement des valeurs extrêmes, le modèle réduit est jugé aussi performant que le modèle complet tout en étant plus parcimonieux.

2.6.2 Logit sur les données winsorisées

Nous allons maintenant appliquer le modèle logit sur les données winsorisées afin d'analyser l'impact de cette transformation sur la significativité des variables et sur la qualité du modèle.
Les résultats obtenus sont présentés dans le tableau suivant :

Variables winsorisées						
	cst	WC/TA	RE/TA	EBIT/TA	ME/TL	S/TA
b	-2,4745044	0,37649174	-2,5384773	-22,977996	-1,1608377	1,40900204
t	-7,7597716	0,45400833	-7,5753398	-4,1862159	-3,8893493	2,48235531
p-value	8,4377E-15	0,64982283	3,5749E-14	2,8364E-05	0,00010051	0,01305171
pseudo-R^2	0,25479324	0,25479324	0,25479324	0,25479324	0,25479324	0,25479324
LR	183,75673	183,75673	183,75673	183,75673	183,75673	183,75673
P-value-LR	8,4331E-38	8,4331E-38	8,4331E-38	8,4331E-38	8,4331E-38	8,4331E-38
ln(L0)	-360,59969	0	0	0	0	0
ln(L)	-268,72133	0	0	0	0	0
nbre de itrati	20	0	0	0	0	0

FIGURE 2.14 – Résultats du modèle logit appliqué aux 5 ratios winsorisées

À la lecture du tableau ci-dessus, nous remarquons que les p-values associées aux ratios WC/TA et S/TA sont supérieures au seuil de 1 %, et que les autres ratios présentent des p-values très faibles, confirmant leur contribution significative à la prédiction du risque de défaut.
De plus, le pseudo R^2, égal à 0,254, suggère un pouvoir explicatif modéré du modèle.
Afin de poursuivre l'analyse, nous allons éliminer les deux ratios (WC/TA et S/TA) et réestimer le modèle logit uniquement sur les trois variables significatives (RE/TA, EBIT/TA et ME/TL).

b	-2,069092	-2,5850014	-20,035693	-1,2084375
t	-7,5770454	-7,7131361	-3,7217731	-4,0426161
p-value	3,5305E-14	1,2212E-14	0,00019783	5,2858E-05
pseudo-R^2	0,24596893	0,24596893	0,24596893	0,24596893
LR	177,392638	177,392638	177,392638	177,392638
P-value	3,2249E-38	3,2249E-38	3,2249E-38	3,2249E-38
ln(L0)	-360,59969	0	0	0
ln(L)	-271,90337	0	0	0
nbre de itrati	20	0	0	0

FIGURE 2.15 – Résultats du modèle logit appliqué aux 3 ratios winsorisées

On remarque que toutes les p-values sont inférieures au seuil de 1 %, ce qui signifie que l'ensemble des variables retenues sont statistiquement significatives dans le modèle.
De plus, le pseudo R^2 est égal à 0,246, soit une valeur très proche de celle obtenue (0,254). Cela indique que la suppression des deux ratios n'a pas dégradé la qualité globale du modèle.

LR	6,3640924
p-val	0,04150065

FIGURE 2.16 – comparaison de modèle à 5 paramètres et celui à 3

On effectuant la comparaison des deux modèles, la p-value obtenue est égale 0.04, ce qui est supérieur au seuil de 1 %. Par conséquent, aucune amélioration significative n'est apportée et nous ne pouvons pas conclure à propos la significativité du modéle.

Conclusion

Au terme de cette analyse, nous avons constaté une confusion initiale liée à l'interprétation conjointe des tests de significativité individuelle (Wald) et du test de vraisemblance dans le cadre du modèle logit appliqué à nos cinq ratios financiers. Bien que le test de vraisemblance confirme la significativité globale du modèle, deux ratios demeurent l'inclusion individuellement, ce qui nous a conduits à examiner leur impact en les excluant du modèle. Le calcul de la statistique LR a produit un écart positif, comme attendu, mais la p-value obtenue avant winsorisation (0.18) est restée supérieure au seuil de 1%, ne permettant aucune conclusion statistique. Après application d'une winsorisation à $\alpha = 1\%$, les résultats se sont révélés similaires, même si la p-value associée à l'écart (0.04) a diminué, sans toutefois atteindre le seuil requis pour conclure à une significativité. Ces constats indiquent que les deux ratios restent faiblement contributifs au modèle et soulignent la nécessité d'approfondir l'analyse ou de considérer des transformations.
Cette analyse nous conduit naturellement à explorer, dans le chapitre suivant, le modèle **probit** afin d'évaluer s'il offre une alternative plus adaptée dans l'estimation de la probabilité de défaut.

Chapitre 3

Modèle de Probit

Dans ce chapitre, nous présentons un modèle qui s'inspire fortement du modèle précédent et qui traite la même problématique, tout en introduisant quelques modifications notables. Nous continuons à estimer les paramètres à l'aide de l'algorithme basé sur la fonction de score, mais avec un changement majeur : la probabilité de défaut de l'individu i est désormais modélisée via la fonction probit appliquée à son score. La fonction probit correspond à la fonction de répartition de la loi normale centrée et réduite, établissant ainsi une relation entre le score de l'individu et sa probabilité de défaut en adoptant une approche fondée sur la distribution normale standard.

3.1 Modèle Probit et Estimation des Paramètres

La fonction Probit est définie comme suit :

$$F(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} \, dy, \quad \forall y \in \mathbb{R}$$

La densité associée à la fonction de répartition F(x) est tout simplement la densité de la loi normale standard càd

$$F'(x) = f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

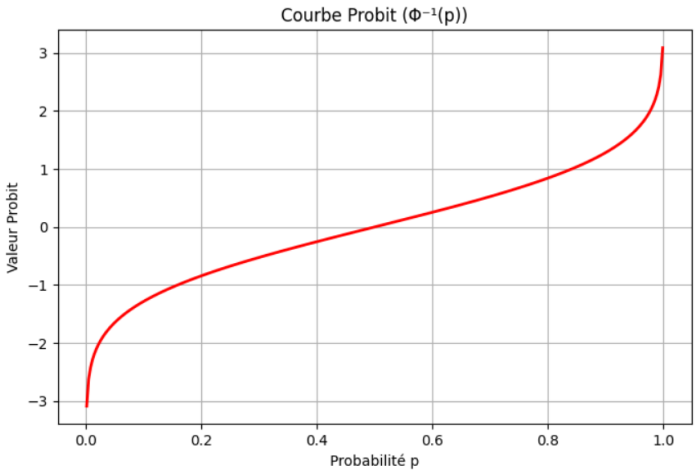


FIGURE 3.1 – Probit

La figure ci-dessus correspond à la fonction Probit, définie comme la réciproque de la fonction de répartition de la loi normale centrée réduite. Elle est largement utilisée en économétrie, notamment dans les modèles de choix binaires, où elle repose sur la distribution cumulative normale standard. Elle s'inscrit également dans le cadre des modèles linéaires généralisés, au même titre que le modèle Logit et le modèle Probit lui-même.
Maintenant, on va appliquer le principe du maximum de vraisemblance :

$$L_i(b) = F\big(b^\top x_i\big)^{y_i}\big(1 - F(b^\top x_i)\big)^{1-y_i} \quad \text{où} \quad y_i = \begin{cases} 1 & \text{s'il y a défaut} \\ 0 & \text{sinon} \end{cases}$$

$$L_i : \text{Loi de Bernoulli de paramètre } p = F(b^\top x_i), \quad (i \in \{1, \ldots, N\})$$

La vraisemblance de l'échantillon alors est définit comme suit :

$$L(b) = \prod_{i=1}^{N} L_i(b) = \prod_{i=1}^{N} \left[F(b^T x^i)^{y_i}\,(1 - F(b^T x^i))^{1-y_i}\right]$$

en appliquant le logarithme, on obtient :

$$ln(L(b)) = \sum_{i=1}^{N} (y_i ln(F(b^T x_i)) + (1 - y_i) ln(1 - F(b^T x_i)))$$

maintenant, en appliquant le derivé par rapport à b

$$\frac{\partial \ln(L(b))}{\partial b_j} = \sum_{i=1}^{N} \left[y_i \frac{F'(b^T x_i)}{F(b^T x_i)} x_{ij} - (1 - y_i) \frac{F'(b^T x_i)}{1 - F(b^T x_i)} x_{ij} \right]$$

donc

$$\nabla_b \ln(L(b)) = \sum_{i=1}^{N} \left[y_i \frac{F'(b^T x_i)}{F(b^T x_i)} x_{ij} - (1 - y_i) \frac{F'(b^T x_i)}{1 - F(b^T x_i)} x_{ij} \right]$$

Par la suite on aura besoin de l'expression de la matrice Hessienne :

$$\frac{\partial^2 \ln(L(b))}{\partial b_j \partial b_k} = \sum_{i=1}^{N} y_i x_{ij} x_{ik} \left[\frac{F''(b^T x_i)}{F(b^T x_i)} - (\frac{F'(b^T x_i)}{F(b^T x_i)})^2 + \frac{F''(b^T x_i)}{1 - F(b^T x_i)} + (\frac{F'(b^T x_i)}{1 - F(b^T x_i)})^2 \right] -$$

$$x_{ij} x_{ik} \left[\frac{F''(b^T x_i)}{1 - F(b^T x_i)} + (\frac{F'(b^T x_i)}{1 - F(b^T x_i)})^2 \right]$$

3.2 Modélisation

3.2.1 Probit sur les données non winsorisées

Nous avons utilisé le modèle probit pour estimer les coefficients $b_0, b_1, \ldots, b_5$ correspondant à nos cinq ratios financiers. L'estimation a été effectuée à l'aide de l'algorithme de Newton-Raphson, qui a pour objectif de maximiser la fonction de vraisemblance.

Variables non winsorisées						
	cst	WC/TA	RE/TA	EBIT/TA	ME/TL	S/TA
b	-1,6732544	0,14521422	-0,8545776	-4,3738095	-0,3652731	0,41925753
t	-15,336495	0,5383088	-7,6355083	-3,2358579	-4,4912732	2,2644879
p-value	0	0,59036388	2,2427E-14	0,00121278	7,0799E-06	0,02354412
pseudo-R^2	0,21761425	0,21761425	0,21761425	0,21761425	0,21761425	0,21761425
LR	156,943261	156,943261	156,943261	156,943261	156,943261	156,943261
P-value-LR	4,4352E-32	4,4352E-32	4,4352E-32	4,4352E-32	4,4352E-32	4,4352E-32
ln(L0)	-360,59969	0	0	0	0	0
ln(L)	-282,12806	0	0	0	0	0
nbre de itrati	8	0	0	0	0	0

FIGURE 3.2 – Résultats du modèle Probit appliqué aux 5 ratios non winsorisées

D'après les résultats obtenus, nous remarquons que les p-values des ratios WC/TA et S/TA sont supérieures au seuil de 1% et que les autres ratios (RE/TA, EBIT/TA et ME/TL) présentent des p-values inférieures au seuil de 1% traduisant leur significativité statistique et leur contribution importante à la qualité du modèle.
De plus, le pseudo-R^2, égal à 0,217, indique une capacité explicative modérée mais satisfaisante pour un modèle Probit appliqué à des données financières.
Enfin, le test du rapport de vraisemblance (LR = 156,94) est hautement significatif, ce qui confirme la validité statistique globale du modèle et la pertinence des variables explicatives retenues.

b	-1,5385733	-0,8426174	-3,8553452	-0,3723833
t	-16,723254	-7,6559871	-2,8506645	-4,6376122
p-value	0	1,9096E-14	0,0043628	3,5246E-06
pseudo-R^2	0,21055051	0,21055051	0,21055051	0,21055051
LR	151,848895	151,848895	151,848895	151,848895
P-value-LR	1,0517E-32	1,0517E-32	1,0517E-32	1,0517E-32
ln(L0)	-360,59969	0	0	0
ln(L)	-284,67524	0	0	0
nbre de itrati	8	0	0	0

FIGURE 3.3 – Résultats du modèle Probit appliqué aux 3 ratios non winsorisées

Après avoir retiré les ratios WC/TA et S/TA, le modèle Probit a été réévalué sur les 3 ratios restants (RE/TA, EBIT/TA et ME/TL).
Les résultats montrent que toutes les variables conservent une p-value inférieure au seuil de 1% ce qui confirme leur forte significativité statistique. Ces ratios exercent donc une influence déterminante sur la probabilité de défaut des entreprises. De plus le pseudo-R^2 obtenu est de 0,210, très proche de celui du modèle précédent, ce qui traduit une stabilité de la capacité explicative malgré la suppression des deux ratios WC/TA et S/TA.
L'étape suivante consiste à effectuer le test du rapport de vraisemblance (Likelihood Ratio Test) afin de comparer le modèle à 5 paramètres (modèle initial) et celui à 3 paramètres.

LR	5,09436613
p-val	0,07830193

FIGURE 3.4 – comparaison de modèle à 5 paramètres et celui à 3

Le résultat obtenu présente une p-valeur de 0,07, supérieure aux seuils usuels de 1%. Cela

signifie que la suppression des deux ratios n'engendre pas de perte d'information statistiquement significative.
Ainsi, avant traitement des valeurs extrêmes, le modèle réduit est jugé aussi performant que le modèle complet tout en étant plus parcimonieux.

3.2.2 Probit sur les données winsorisées

Nous allons à présent réappliquer le modèle Probit, cette fois sur les données ayant subi la winsorisation.

Variables winsorisées						
	cst	WC/TA	RE/TA	EBIT/TA	ME/TL	S/TA
b	-1,5754332	0,22167095	-1,3803032	-11,147191	-0,2640775	0,7603007
t	-11,425998	0,57886769	-8,4961277	-4,3581451	-3,245498	2,86020454
p-value	0	0,56267845	0	1,3117E-05	0,00117245	0,00423368
pseudo-R^2	0,25212785	0,25212785	0,25212785	0,25212785	0,25212785	0,25212785
LR	181,834448	181,834448	181,834448	181,834448	181,834448	181,834448
P-value-LR	2,1708E-37	2,1708E-37	2,1708E-37	2,1708E-37	2,1708E-37	2,1708E-37
ln(L0)	-360,59969	0	0	0	0	0
ln(L)	-269,68247	0	0	0	0	0
nbre de itratio	8	0	0	0	0	0

FIGURE 3.5 – Résultats du modèle Probit appliqué aux 5 ratios winsorisées

Une winsorisation au niveau $\alpha = 1\%$ a ensuite été appliquée afin de limiter l'influence des valeurs extrêmes sur les ratios financiers. Cette transformation vise à réduire la variance des estimateurs et à améliorer la stabilité du modèle. Après réestimation du modèle Probit sur la base winsorisée, les résultats du test de Wald demeurent similaires : un coefficient conserve le p-valeurs supérieures à 1%. Cependant, le test global du rapport de vraisemblance reste significatif (p-valeur $< 1\%$), montrant que le modèle dans son ensemble demeure pertinent.

b	-1,5675596	-1,3700271	-11,095614	-0,2548658	0,79435839
t	-11,46733	-8,4793361	-4,3311822	-3,2015972	3,08514699
p-value	0	0	1,4831E-05	0,00136668	0,00203452
pseudo-R^2	0,25166655	0,25166655	0,25166655	0,25166655	0,25166655
LR	181,50176	181,50176	181,50176	181,50176	181,50176
P-value-LR	3,5482E-38	3,5482E-38	3,5482E-38	3,5482E-38	3,5482E-38
ln(L0)	-360,59969	0	0	0	0
ln(L)	-269,84881	0	0	0	0
nbre de itratio	8	0	0	0	0

FIGURE 3.6 – Résultats du modèle Probit appliqué aux 4 ratios winsorisées

On remarque que toutes les p-values sont inférieures au seuil de 1 %, ce qui signifie que l'ensemble des variables retenues sont statistiquement significatives dans le modèle.
De plus, le pseudo R^2 est égal à 0,251, soit une valeur très proche de celle obtenue (0,252). Cela indique que la suppression d un ratio n'a pas dégradé la qualité globale du modèle.

LR	0,33268781
p-val	0,56408068

FIGURE 3.7 – comparaison de modèle à 5 paramètres et celui à 4

On effectuant la comparaison des deux modèles, la p-value obtenue est égale 0.56, ce qui est supérieur au seuil de 1 %. Par conséquent, aucune amélioration significative n'est apportée et nous ne pouvons pas conclure à propos la significativité du modéle

Conclusion

L'étude Probit menée sur les ratios financiers, avec et sans winsorisation, a montré que certains coefficients apparaissent non significatifs selon le test de Wald, alors que le modèle reste globalement significatif au seuil de 1%. Cependant, la suppression de ces coefficients et l'évaluation de la perte d'information via la statistique du rapport de vraisemblance n'ont révélé aucune différence significative ($p-value > 1\%$), indiquant que leur exclusion n'apporte pas d'amélioration interprétable au modèle.

Cette situation suggère que la contribution des ratios concernés s'exprime davantage de manière collective plutôt qu'individuelle, et confirme que la spécification initiale du modèle demeure la plus cohérente dans le cadre du scoring de défaut.

Conclusion et perspectives

L'analyse réalisée à l'aide des modèles Logit puis Probit a montré que, malgré une significativité globale convaincante selon le test de vraisemblance, certains ratios demeurent inclusifs individuellement au regard du test de Wald. La suppression de ces coefficients suivie du calcul du test du rapport de vraisemblance n'a pas permis d'obtenir une amélioration interprétable, puisque les p-values associées sont restées supérieures au seuil de 1 %, aussi bien avant qu'après la winsorisation. Bien que la winsorisation à 1 % ait légèrement modifié p-values (notamment dans le modèle Logit où la p-value est passée de 0.18 à 0.04) elle n'a pas suffi à rendre réellement indispensables les coefficients initialement inclusifs. Ces résultats suggèrent que les variables concernées contribuent davantage collectivement qu'individuellement à la performance prédictive du modèle de scoring.

Cependant, ces constats ouvrent des perspectives méthodologiques intéressantes pour améliorer la stabilité et l'interprétation des coefficients, notamment via des techniques de rééquilibrage ou de correction des données. Parmi les approches envisageables, on peut citer la standardisation robuste, le resampling (SMOTE, undersampling) ou encore des méthodes pénalisées telles que le Lasso et l'Elastic Net, capables de sélectionner automatiquement les variables pertinentes. Ces outils pourraient permettre d'améliorer la significativité individuelle et de clarifier la structure explicative du modèle. Ainsi, ce travail constitue une première étape vers une optimisation méthodologique plus avancée de la modélisation du risque de défaut.